



天数智芯

中国头部通用GPU 芯片及算力系统提供商

做算力引擎 创世界一流

目 录

01

公司概况

Company Overview

02

核心产品

Core Products

03

方案应用

Solution & Application

01

公司概况

Company Overview

中国领先的通用GPU高端芯片 及超级算力系统提供商

团队规模700+


落地上海、北京、深圳、南京、西安

天垓100，2018年设计，中国首款自主通用GPU

历经4代技术迭代，沉淀标准化设计方法论与丰富工程实践经验，核心设计能力趋于成熟稳定

计算核心指令集及软件栈具备完整自主知识产权

落地350+企业，覆盖20+行业，出货75K+芯片



2018

正式启动通用
GPU芯片设计

2021

发布首款通用
GPU训练产品
天垓Gen1

2022

发布通用GPU
推理产品智铠
Gen1、智铠
Gen1X

2023

发布通用GPU
产品天垓Gen2

2024

发布通用
GPU产品天
垓Gen3

2026

发布通用
GPU新品

工信部专精特新重点“小巨人”

上海市 2024工人先锋号

上海市/北京市
国家级高新技术企业

上海市 2024科技小巨人

上海市/北京市
专精特新企业

上海市五一劳动奖状

北京市园区类博士后工作站

上海市重点服务独角兽企业


北京市通用人工智能产业创新伙伴计划 – 算力伙伴

02

核心产品


Core Products

天垓[®] 训推产品系列




天垓100

国内首款
通用GPU训练产品



天垓150/150S/1500AM

训推一体
千锤百炼



天垓200

实测算力&运算效率
全线超越



天垓300

更高精度
更强性能

智铠 推理产品系列



智铠50

轻巧体量
边缘推理加速卡



智铠100

高性价比
大模型推理加速卡



智铠100 DUO

性能更强劲
推理加速卡



智铠100X

自主可控
轻量级推理加速卡



智铠300

千亿级LLM
推理加速卡

彤央边端AI算力产品



彤央 TY1000

边端 AI 算力模组



CPU	GPU
8-Core ARM	天数智芯自研 GPU
192 TOPS	
内存	16GB
显存	16/32GB
100 x 87 x 15.29 mm	
699 Pin	

彤央 TY1100

边端 AI 算力模组



CPU	GPU
12-Core ARM	天数智芯自研 GPU
230 TOPS	
内存	16GB
显存	16/32GB
100 x 87 x 42.5 mm	
699 Pin	

彤央 TY1100_NX

边端 AI 算力终端



CPU	GPU
12-Core ARM	天数智芯自研 GPU
130 TOPS	
内存	16GB
显存	32/64GB
130 x 130 x 63 mm	
即插即用	

彤央 TY1200

边端 AI 算力终端




CPU	GPU
16-Core x86	天数智芯自研 GPU
300 TOPS	
内存	32GB
显存	16/32GB
120 x 120 x 53 mm	
即插即用	

天垓-智铠系列产品



型号	智铠100	智铠100Duo	天垓150S
产品形态	PCIe全高全长单宽	PCIe全高全长双宽	PCIe全高全长双宽
GPU 架构	通用 GPU	通用 GPU	通用 GPU
单精浮点峰值算力 (FP32)	24 TFLOPS	48 TFLOPS	56 TFLOPS
半精浮点峰值算力 (FP16/BF16)	96 TFLOPS	192 TFLOPS	224 TFLOPS
整型int8峰值算力	>300 TFLOPS	>640 TFLOPS	>640 TFLOPS
内存配置	32GB HBM2e, 带宽800 GB/s	64GB HBM2e, 带宽1.2 TB/s	64GB HBM2e, 带宽1.2 TB/s
P2P互联	双向64GB/s	双向64GB/s	双向64GB/s
主机接口	PCIe 4.0 x 16	PCIe 4.0 x 16	PCIe 4.0 x 16
编解码能力	视频解码格式: HEVC/AVC/VP9/AVS2 视频解码最高分辨率: 8k H264解码@1080P(fps): 7680 H265解码@1080P(fps): 7680 图片编码@1080P(fps): 500 图片解码@1080P(fps): 2000	视频解码格式: HEVC/AVC/VP9/AVS2 视频解码最高分辨率: 8k H264解码@1080P(fps): 7680 H265解码@1080P(fps): 7680 图片编码@1080P(fps): 1000 图片解码@1080P(fps): 4000	视频解码格式: HEVC/AVC/VP9/AVS2 视频解码最高分辨率: 8k H264解码@1080P(fps): 7680 H265解码@1080P(fps): 7680 图片编码@1080P(fps): 1000 图片解码@1080P(fps): 4000
功耗	板级功耗 150W (支持DVFS)	板级功耗 350W (支持DVFS)	板级功耗 450W (支持DVFS)
散热方式	被动散热	被动散热	被动散热
封装	2.5D CoWoS 封装	2.5D CoWoS 封装	2.5D CoWoS 封装
虚拟化	支持	支持	支持
板卡工作环境温度	0°C~45°C (建议温度 0°C~35°C)	0°C~45°C (建议温度 0°C~35°C)	0°C~45°C (建议温度 0°C~35°C)
板卡存储温度	-40°C~70°C	-40°C~70°C	-40°C~70°C

天数智芯 IXUCA 软件栈



成熟的应用生态



模型算法类别	模型算法系列/名称				
大语言模型	ByteDance系列	Qwen系列	DeepSeek系列	LLaMA系列	客户合作闭源模型系列
	•豆包 seed-oss •UI-TARS-1.5-7B	•Qwen3.5-397B/122B/35B/27B等 •Qwen3-0.6B/1.7B/8B/14B/30B/32B •Qwen3-235B-A22B-Instruct •Qwen2.5 – 7B/14B/32B •Qwen2.5-Coder-32B-Instruct	•DeepSeek – v3/v3.1 •DeepSeek – R1 •DeepSeek R1 – Distill –Qwen / LLaMA 各参数量模型	•LLaMA2 – 7B/13B/70B •LLaMA3 – 8B – Chinese -Chat •LLaMA3 – 8B / 70B •CodeLLaMA – 13B	•STEP3.5/3等（闭源） •GLM5/GLM4.5等（闭源） •MinMax2.5/2.1等（开源） •CodegeeX – 6B（闭源） •aiXcoder – 16B（闭源）
多模态模型	CLIP & Diffusion系列	Qwen-VL 系列	FLUX.1 系列	LLaVA 系列	MiniCPM-V 系列
	图文匹配/文生图 •CLIP •Stable Diffusion 3/v1.5/v2.1/XL •... ..	视觉对话/理解 •Qwen2.5-VL/7B GRPO/7B-Instruct •Qwen2-VL/7B-Instruct •Qwen-Audio-Chat	文生图 •FLUX.1-dev •FLUX.1-schnell	视觉问答/对话 •LLaVA •LLaVA 1.5-13b/7b-hf •LLaVA-Next-Video-7B	轻量级VLM •MiniCPM/MiniCPM-o-2_6 •MiniCPM-V2 /2_6 •MiniCPM-Llama3-V-2_5
视觉模型	通义万相系列	XX混元系列	GLM-4V系列	InternLM3系列	BLIP 系列
	文生视频 •Wan2.1/2.2	文生视频 •HunyuanVideo	视觉对话/理解 •GLM-4V	视觉对话/理解 •InternLM3	视觉理解/生成 •BLIP
视觉模型	通用感知基石系列	轻量化与高效系列	高精度实时检测系列	前沿与复杂理解系列	专业化定位与分割系列
	•ResNet18/34/50/101/152 •OCR/DeepSeek-OCR •PaddleOCRv3.1.0/dots.ocr	•EfficientNet-B0-B5 •EfficientNetV2_s/m/rw_t •DabNet	•YOLO V3-V13 •ATSS •Cascade R-CNN	•Swin Transformer •BEVFormer/BEVFusion •SparseDrive stage1	•Attention U-Net •3D U-Net •DeepLabV3/V3+
语音模型	语音合成系列	语音识别系列		音频理解合成系列AUDIO	
	•CosyVoice2-0.5B •PP-TTS-FastSpeech2/HiFiGAN •Tacotron2/WaveGlow	•Whisper •Conformer /Efficient Conformer v2/ U2++ Conformer/ Unified Conformer/ PP-ASR-Conformer •Transformer /Transformer ASR/RNN-T		•Belle-whisper-large-v3-zh •CosyVoice-300M-Instruct •Edge-tts-zh	
科学计算	•DeePMD	•TorchMD	•NequIP	•Allego	•Equiformer
	•lammps	•Gromacs			
通用计算	•RTM	•PSTM	•QRTM		
数字信号处理	•FFT	•IR滤波	•SAR		
其他搜索/推荐	•Bert-base/Large	•DLRM	•NCF	•Wide&Deep	•DeepFM/xDeepFM

标准机架式服务器



- 标准机架式服务器：2U/4U
- CPU选择：支持各类市场主流CPU产品
- GPU配置：
 - 天垓产品单机最多可配置8卡
 - 智铠产品单机最多可配置16卡

工作站



- CPU选择：支持各类市场主流CPU产品；可根据工作站机型支持桌面级CPU
- GPU配置：1/2/4/8卡智铠系列产品
- 产品优势：噪音小，易搬运，轻运维
- 适用场景：办公室、会议室、小型团队

工控机



- CPU选择：支持各类市场主流CPU产品；可根据工控机整机机型支持桌面级CPU
- GPU配置：智铠/彤央系列产品
- 支持多路视频解码
- 支持百种AI算法部署
- 支持大模型应用轻量级部署

丰富的应用生态

300 +

采购用户

1000

联合开发案例



智算




医疗



大模型



基因



地质



金融



教育



交通



零售



工业



通讯




互联网



数字人



营销



科学



电力




司法



政务

实测性能高，效率超过国际主流产品



产品特点:

开箱即用，体验无忧

✓ 开放性强，主流生态兼容，平滑切换 **零**成本



✓ 拒绝人海战术，以 **小时** 为单位的切换时间

- GLM4-9B-Chat 发布当天开发者自行完成适配

✓ 捍卫客户代码主权，尽享自由开发乐趣

- 开发者基于天数智芯产品自行搭建应用，300支开发者队伍搭建应用近700次，涵盖医疗、金融、教育、营销、设计、智能办公等10余个不同领域

整体交付

ALL
in
ONE

01 整体硬件

灵活的整体硬件选型
满足不同业务需求

02 软件平台

稳定可靠的全栈式软件平台
历经真实项目打磨验证

03 解决方案

结合业务场景
精选行业头部垂直解决方案

04 售后交付

具备真实交付经验
提供完善售后服务

03

方案应用

Solution & Application

万卡部署，算力新基建

作为国内领先通用GPU算力服务商，天数智芯已搭建并交付了高达万卡的算力集群部署，具备系统搭建、技术实施、运维支持等多样化交付经验，为各级客户及合作伙伴提供高效算力服务。



全向箱 - 天数智芯自主开发的集群管理平台



大模型训练面临的
算力困境

难！

受限于宏观环境，
难以获得大量国外
先进算力

不同厂商芯片架构
不同，难以在
同一集群中发挥
最大效能

国内 **首家** 支持高效异构混合训练方案的AI芯片厂商

- 2023年11月，天数智芯与合作伙伴完成首个中外芯片混合训练的大模型 Aquila2 - 70B - Expr，该模型基于千卡异构算力集群，性能达到两个集群独立训练之和的92%，并在精度上与国际主流集群训练权重文件相当。
- 2024年5月，支持更多异构混训技术，在保证异构集群整体训练效率和模型精度的前提下，在天数智芯通用GPU加速卡与国外先进算力加速卡1:1配置时性能大幅提升，系统配置更加灵活。
- 2025年1月，实现与国内外多家芯片进行两两混训，整体异构混训集群效率升至97.5%，通过攻克不同芯片架构间协同工作的技术难题，有效提升了国际主流算力与自主可控算力混合训练的效率与稳定性。

大模型： 高效异构混合训练方案-众智FlagOS



- 端到端训练芯片验证数据
- Qwen3-0.6B评测结果

端到端训练芯片验证数据概览（芯片均达到对齐，正数是优于基线）

芯片厂商	FlagOS的Triton算子替换率	与英伟达基线评测偏差
天数智芯	100%	-0.43%
沐曦	95.7%	-0.58%
寒武纪	86.5%	0.39%
海光	84.4%	-0.65%
摩尔线程	83.6 %	1.65%
昆仑芯	80%	0.29%

分类	数据集	英伟达基线	沐曦训练	寒武纪训练	摩尔训练	天数训练	海光训练	昆仑芯训练
英语常识推理	HellaSwag (5-shot)	0.4107	0.4214	0.4164	0.4215	0.4114	0.4181	0.4212
	TruthfulQA (0-shot)	0.2399	0.2154	0.2375	0.2228	0.2203	0.2277	0.2326
	Winogrande (5-shot)	0.562	0.5691	0.5675	0.5746	0.5588	0.5612	0.5746
	CommonsenseQA (5-shot)	0.1916	0.1941	0.1974	0.1941	0.1998	0.2015	0.1966
	BoolQ (5-shot)	0.5979	0.555	0.574	0.6391	0.5749	0.5303	0.567
英语知识运用	ARC Easy (5-shot)	0.6524	0.6688	0.6738	0.6709	0.6582	0.6591	0.6684
	ARC Challenge (5-shot)	0.3055	0.3097	0.2986	0.3174	0.3097	0.3131	0.2961
	MMLU (5-shot)	0.2757	0.2683	0.2525	0.2524	0.2557	0.2657	0.2643
	PIQA (5-shot)	0.7231	0.7193	0.7252	0.7187	0.7089	0.7171	0.7269
	OpenBookQA (5-shot)	0.23	0.234	0.25	0.246	0.246	0.256	0.244
英语数学能力	GSM8K (5-shot)	0.0121	0.0159	0.0129	0.0182	0.0167	0.0121	0.0129
	Minerva Math (4-shot)	0.0067	0.011	0.0084	0.0051	0.0051	0.0084	0.0067
中文知识运用	CEval (5-shot)	0.237	0.2363	0.2474	0.2385	0.2563	0.2459	0.2504
	CMMLU (5-shot)	0.2513	0.2505	0.2526	0.2542	0.2538	0.249	0.2477
总平均	总平均	0.3354	0.3335	0.3367	0.341	0.334	0.3332	0.3364
百分比差异		-	-0.58%	0.39%	1.65%	-0.43%	-0.65%	0.29%


大模型：高效异构PD分离推理方案

通过异构推理方案，
与国际同构集群方案相比，
更具**高性价比**

通过**通讯协议优化**，
P端KVcache直接传送D端，
提高通讯效率，
节省总体计算时间

通过**集群调度方案**，
并行处理不同请求时，
使P、D阶段都在其最优性能下运行，
提高了系统吞吐量

图表标题



2台150S+1台H200 **VS** 2台H200
性能 **2倍** 以上，性价比 **1.5倍** 以上




Deepseek PD分离异构方案




- PD分离异构方案：天垓150s prefill，英伟达H系列（如H200，H20） decode；
- 性价比：Prefill throughput超英伟达和NPU，性价比为英伟达的1.5倍，NPU的2倍；
- 案例：已在北京互联网客户在某APP业务中部署上线

机器配置	配置 (基于 sglang)	场景	inputlen	outputlen	concurr ency	Input token throughput	Output token throughput	meanTTFT(ms)	meanITL(m s)	meanE2E(ms)	QPM(Query Per Minute)
2台BI150S + 1台H200	BI150s : --tp-size "2" --pp- size "8" -- chunked -prefill- size "2048"	定长	6144	1024	143	22990	3831	1786.62	35.69	38290.7	224.4
			6144	1024	30	8572	1428	1540.42	19.54	21527.11	84
			5632	512	28	13753	1250	1480.8	19.96	11681.34	146.4
			3584	1024	225	18542	5297	2032.41	40.56	43518.87	310.2
			2048	200	130	31785	3104	1655.71	33.55	8327.17	931.2
		变长 正态分布	2048	200	113	28804	2825	1893.72	30.78	8010.38	848.4
		变长 0-10K随机分 布	3566	1024	202	17677	5074	1798.16	38.03	40699.75	297.6
两台H200	tp8	定长	6144	1024	82	14466	2410	1521.95	32.75	34987	141.6

交通案例：某市车路云一体化项目




多方协作机制



硬件选型



更多硬件选型



应用实效

330 个路口部署

2 项国家标准贡献
2 项行业标准贡献

更多合作伙伴



交通案例：轨道交通



X



天数智芯
Iluvatar CoreX

功能设计：

▶ 视频解析

- 实时视频分析：加速视频分析算法的运行，实现对实时视频的快速解析，提高监控效率。
- 历史视频回溯：加速历史视频的回溯和分析，帮助安保人员查找特定事件或人物。

🚆 地铁安检

配合X光机等设备，可以实现违禁物品、危险物品的快速检测，确保乘客安全，提高安检效率


🚶 进站识别

为人脸识别提供强大的算力支撑，利用人脸识别技术实现快速进站，提高通行效率。

🎯 站内追踪

利用人脸识别技术、人体识别技术、行为识别技术可以快速识别、定位异常行为的人，协助安保人员及时发现异常、对异常事件进行快速回溯定位

- GPU：3 x 智铠50A/每站点
- 整机：2U服务器



项目难点：

业主因应多元业务场景，先后引入多家专业软件厂商的异构解决方案，各团队技术栈、接口规范及开发节奏互不相干；依托统一的算力底座，系统需以同规格、同品质、同优先级的计算资源无差别地供给所有应用，并具备弹性伸缩与负载感知能力，使各模块在高并发或低谷期均能稳获所需算力，从而保障整体运行的持续平稳与高效。

天数方案：

采用天数智芯vGPU方案，同一张GPU加速卡可切分至多达100份算力，且每份算力的有效利用率均可达到95%以上。

95%+

具身智能：某单位机器狗项目

客户诉求

在机器狗有限的本体空间内置入自主算力，需实现多传感器融合感知，适应复杂环境的运行；支持语音交互。

项目难点


多模态融合（摄像头、激光雷达、语音信号）；多传感器（陀螺仪、加速度传感器等）数据处理+动作控制要求整体响应快延迟低。

技术方案


采用ROS通信框架，实现模块解耦与多传感协同，集成slam、高程图、运动控制等组件；采用本地化大模型部署，提高语义理解能力。

方案亮点

感知-语义理解-动作响应，全流程延迟 $\leq 100\text{ms}$ ；支持在无网络环境下运行，无需依赖云端算力，确保机器狗具备更强的独立自主AI能力；模块化设计支持不同本体结构，适配多款机器狗本体，具备高度可复制性。



具身智能：格蓝若机器人



流程

接收语音->理解意图->反馈->感知->规划->行动

优势

- 自然交互：支持语音输入与语音反馈，免手动操作。
- 高精度感知：结合 YOLOv8 与 SLAM，实现精准定位与避障。
- 低延迟控制：CPU 执行运动控制，响应快。
- 可扩展性强：可替换 LLM / 视觉模型，适配多场景任务。

彤央产品能力-性能数据

我们已完成与浙江人形机器人创新中心的联合模型验证，客户实测性能数据显著优于预期，充分验证了平台在真实场景下的稳定性与高效性。

针对典型的边缘侧模型（如图像分类、目标检测、语音识别等），我们开展了系统性测试，实测性能数据表明平台具备优异的推理效率与资源利用率，全面满足实时AI应用需求。

浙江人形机器人创新公司算法

模型名	性能要求	实测结果
MobileNetV2	20fps	4151fps
efficientnet-b7	30fps	70fps
mobileSAM	1fps	42fps
graspnet	1fps	4.70fps
foundtionpose	1fps	3.38fps



典型模型

编号	模型名称	精度	性能fps
分类	resnet50	int8	4939.414
		fp16	2466.532
	resnet101	int8	3513.493
		fp16	1554.414
	vgg16	int8	2849.781
		fp16	1233.532
检测	yolov3	int8	530.368
		fp16	511.836
	yolov5m	int8	789.353
		fp16	418.327
	yolov7m	int8	482.020
		fp16	262.095
	dbnet	int8	201.28
		fp16	132.82
npl	bert_large	int8	239.89
		fp16	165.785
speech	conformer	fp16	507.625

大模型方面，我们平台已完成多款主流模型的适配与测试。测试结果显示：平台具备良好的运行效率与稳定性，支持边缘侧本地部署，为大模型上端应用提供坚实算力基础。

针对大模型，我们重点测试了以下几类算法在边缘平台上的运行性能，实测结果如下：

模型列表	TPS	FTL(ms)
Yi-6B-Chat	20.366	237.787
Qwen2-7B-Instruct-GPTQ-Int4	27.581	323.125
ChatGLM3-6B	20.119	262.337
glm-4-9b-chat-GPTQ-Int4	18.785	404.044
Meta-Llama-3-8B-Instruct-GPTQ	24.648	125.082
DeepSeek-R1-Distill-Qwen-1.5B-AWQ	29.676	86.053
DeepSeek-R1-Distill-Qwen-7B-AWQ	27.016	310.894
DeepSeek-R1-Distill-Qwen-14-AWQ	17.697	620.140


产品特点

- CUDA兼容，算法部署敏捷，迁移成本低，算力效率高
- 实测性能高，性价比远超国内同类产品
- 合规稳定供应，后续持续迭代
- 字节硬件团队测评：<https://bytemlperf.ai/zh/blog/ts.html>

兼容	计算框架	计算库
支持对应特性，但具体实现不同	torch	tensorflow
不支持	paddle	megatron
	deepspeed	...
		cuDNN
		cuFFT
		cuBLAS
		cuRand
		cuSolver
		...

多节点通信	CUDA kernel 语法
P2P DMA	grid/block/warp 层级
NCCL reduce / gather ...	shared memory
	各类 alu / sfu 指令
	内存 / 指令 barriers
	Tensor Core
	warp level MMA
	warpSize=64
	cp.async / ldmatrix

驱动层	多device API	编译器和工具	ptx ir
stream / event 多stream并行	CUDA graph	CUDA C++ 语法扩展	时间轴性能工具
	其它CUDA API ...	__global__ ...	kernel性能分析工具



有 SLO 场景 (TTFT<5 S , TPOT < 90ms) : 天数 BI-150S 在 w4a8 量化方案下 , “单位成本吞吐” 优于 H20 (FP8 , SGLang 社区版) , 也优于国内 GPU (w8a8) 方案

模型	卡型	推理引擎	单台卡数	机器数量	input	output	Max-Concurrency (客户端并发数)	Total token throughput (tok/s) (总的每秒吞吐)	Total token throughput (每卡每秒吞吐)	Mean TTFT (ms) (平均首字延迟)	单卡性价比归一化
DeepSeek-R1	H20 96G	sglang优化	8	2	3500	1500	64	4461.00	278.81	3492.33	1.00
DeepSeek-R1	H20 96G	sglang社区	8	1	3500	1500	40	1989.64	124.35	5323.64	0.45
DeepSeek-R1	H20 141G	sglang优化	8	1	3500	1500	32	3316.00	414.50	3789.86	1.33
DeepSeek-R1	友商550	vLLM	8	2	3500	1500	32	489.59	30.60	6047.81	0.14
DeepSeek-R1	友商B3	MindIE	8	2	3500	1500	8	544.98	34.06	3464.16	0.11
DeepSeek-R1	友商B4	MindIE	8	2	3500	1500	10	598.15	37.38	4180.00	0.17
DeepSeek-R1	天垓150S	vLLM优化	8	1	3500	1500	16	585	73.13	4459.37	0.63

无 SLO 场景 : 天数 BI-150S 在 w4a8 量化方案下 , “单位成本吞吐” 为所有国产卡 (w8a8) 方案中最高选择 , 也优于 H20 96G (FP8) 方案

模型	卡型	量化	单台卡数	机器数量	input	output	Max-Concurrency (客户端并发数)	Total token throughput (tok/s) (总的每秒吞吐)	Total token throughput (每卡每秒吞吐)	单卡性价比归一化
DeepSeek-R1	H20 96G	FP8	8	2	3500	1500	90	4594.73	287.17	1.00
DeepSeek-R1	H20 141G	FP8	8	1	3500	1500	128	3455.45	431.93	1.34
DeepSeek-R1	友商B3	int8	8	2	3500	1500	32	1111.20	69.45	0.22
DeepSeek-R1	友商B4	int8	8	2	3500	1500	32	1242.23	77.64	0.35
DeepSeek-R1	友商550	int8	8	2	3500	1500	128	1359.72	84.98	0.37
DeepSeek-R1	友商590	int8	8	2	3500	1500	128	3459.8	216.24	0.863
DeepSeek-R1	天垓150S	w4a8	8	1	3500	1500	64	1111.96	139.00	1.16

天垓150s vs L20



- 算力性能高：FP16算力为2倍，int8算力为3倍

项目	规格	L20规格	L20实测	规格实测占比	BI150s	BI150s VS L20
算力	INT8(M=2048N=2048K=16384 Transpose A:1 Transpose B:1)	239	232.3501	97.22%	768	292.66%
	FP16(M=2048N=2048K=8192 Transpose A:1 Transpose B:0)	119.5	115.3119	96.50%	224	194.26%
	FP32(M=3072N=4096K=30176 Transpose A:1 Transpose B:1)	59.8	55.07925	92.11%	56	101.67%
显存	显存类型	GDDR6			HBM2E	
	容量	48GB			64GB	
	显存带宽	864GB/s			800GB/s*2	
通信	h2d	/	24.2	/	27.8	114.88%
	d2h	/	25.14	/	28.4	112.97%
	d2d	864	659.56	76.34%	1117.8	84.74%

TX L20替代推理测试性能（天垓150s）



- 微信语音模型（96层transformer网络）：**目前天数单卡单路可以达到L20 3.8倍**

	千次单路耗时(ms)	10路耗时(ms)	40路耗时(ms)	80路耗时(ms)
测试路数	1	10	40	80
L20 单卡	37	102	284	550
BI-V150-0.5卡	19	64	210	380

- 搜狗语音模型：**目前天数单卡可以达到L20 1.5倍，0.2B模型，延迟9ms，0.7B模型延迟25ms**

Model	shape	芯数	FPS	QPS	Mean Latency (ms)	P99 Latency (ms)	BI150双芯 / L20	L20 qps	Mean Latency (ms)
0.2B-conformer-fp16	4x187x512	1	437.050	109.263	9.146	9.158	137.50%	158.84	6.31
0.2B-conformer-fp16	4x187x512	2	873.585	218.396	9.148	9.167			
0.7B-conformer-fp16	4x187x1024	1	188.000	47.000	21.270	21.347	146.08%	64.32	15.44
0.7B-conformer-fp16	4x187x1024	2	375.858	93.965	21.272	21.353			
0.2B-transformer-fp16	4x187x512	1	590.089	147.522	6.773	6.833	160.86%	183.38	5.46
0.2B-transformer-fp16	4x187x512	2	1179.978	294.994	6.772	6.780			
0.7B-transformer-fp16	4x187x1024	1	223.027	55.757	17.929	18.189	168.22%	66.41	14.92
0.7B-transformer-fp16	4x187x1024	2	446.886	111.722	17.895	17.957			

TX L20替代推理测试性能（天垓150s）



- Deepseek：优化Prefill性能数据，同时逐步验证天数150搭载星河服务器可行性，目标是该组合跑通且极具性价比

Test Case	单机QPM(TTFT<2s)	单机QPM(TTFT<3s)	单机QPM(TTFT<3.5s)
天数150(450w)+TH服务器	287	336	350
天数150(400w)+XH服务器	261	324	330

- TX 3D模型：支持几何生成（2.6B），纹理合成（1.3B），去光影不变纹理（1.3B）模型，性能超过L20 2倍以上

模型名称	step	L20 cost time(s)	0.5卡-BI150 cost time(s)
几何网格生成	dit shape pipeline	36.15	25.68
纹理生成模型	pait pipeline	402.8	39.03

- LLM变成：目前天数单卡平均可以达到L20 1.8倍

模型	卡数	in	out	QPM/卡数	Mean TTFT (ms)	Mean TPOT (ms)	QPM/卡数 (L20 XX内部数据)	QPM/卡数 (BI150/L20, TX内部 自测)
Qwen2.5-1.5B-Instruct	0.5	变长3500	avg1000	351.619	1317.47	49.526	172.29	204%
Qwen2.5-7B-Instruct	0.5	变长3500	avg1000	92.342	1105.164	50.688	39.04	237%
Qwen3-0.6B	0.5	变长3500	avg1000	139.23	1805.993	46.237	76.21	183%
Qwen3-32B-W8A8	1	变长3500	avg1000	10.639	1885.903	43.256	5.11	208%
Qwen3-32B	2	变长3500	avg1000	5.724	1938.853	49.16	4.04	142%
Qwen3-30B-A3B-Instruct-2507	2	变长3500	avg1000	38.068	1460.599	48.761	29.4	129% 32



做算力引擎 创世界一流